

Введение

Дорожно-транспортные происшествия являются одной из ключевых социально-экономических проблем регионального развития и самой частой внешней причиной смертности в России. Помимо прямых человеческих потерь, аварии создают значительные экономические издержки: медицинские расходы, утрату трудоспособности, инфраструктурный ущерб и снижение качества жизни населения. В условиях цифровизации государственного управления повышается необходимость проводить мониторинг происшествий с использованием методов искусственного интеллекта и машинного обучения для анализа факторов ДТП и прогнозирования их тяжести.

Современные исследования в области дорожной безопасности показывают, что тяжесть аварии определяется совокупностью факторов: погодными условиями, освещенностью, характеристиками дорожной инфраструктуры, типом происшествия, категорией транспортного средства и человеческими факторами. Например, в работе (Becker, Rust, Ulbrich, 2022) показано, что использование обобщённых аддитивных моделей (GAM) позволяет выявлять нелинейные эффекты погодных условий и их взаимодействие с типами ДТП. Аналогично, в своем исследовании (Родионова, Шведян, Кудрявцева 2022) на данных Санкт-Петербурга продемонстрировали значимость инфраструктурных факторов (освещение, дорожные барьеры) и типа аварии при прогнозировании тяжести ДТП.

В большинстве работ применяются либо классические эконометрические модели, либо отдельные ML-алгоритмы без глубокой интерпретации. Однако остаётся открытым вопрос:

позволяют ли методы машинного обучения выявить более сложные эффекты по сравнению с линейными моделями?

Описание данных

Для исследования были использованы детализированные карточки дорожно-транспортных происшествий в регионе с худшей ситуацией по уровню смертности на 100 тысяч жителей человек - 32,7, в Республике Тыва за период с января 2021 года по январь 2026 года. Данные были взяты с сайта официальной статистики ГИБДД (<http://stat.gibdd.ru/>) в виде карточек подробно описывающих случаи ДТП. Было принято решение разделить базу данных на две взаимосвязанные таблицы:

1. «ДТП карточки» - информация о каждом зарегистрированном происшествии.
2. «ДТП участники» - информация о всех участниках ДТП.

Таблицы объединяются по уникальному идентификатору номера ДТП.

В итоге база содержит как характеристики аварии на уровне события, так и характеристики отдельных участников, что позволяет формировать модели для исследования как внешней среды и инфраструктуры (погодные условия, время и место происшествия, освещенность, состояние дорожного покрытия), так и внутренних/индивидуальных (возраст, пол, состояние, признаки нарушения ПДД, категория ТС) причин ДТП.

Предобработка данных и формирование признаков

Перед построением моделей была проведена стандартизированная предобработка и инженерия признаков. В качестве целевой переменной

была выбрана фатальность исхода происшествия. fatal была определена как бинарный индикатор наличия погибших в ДТП: fatal = 1 - есть хотя бы один погибший, fatal = 0 - погибших нет.

Дата происшествия была разделена на year (год происшествия), month (месяц), dow (день недели), is_weekend (индикатор выходного дня), hour (час суток). Добавление временных признаков позволяет учитывать сезонность и суточные эффекты аварийности.

Категориальные признаки (тип ДТП, состояние погоды, освещение, состояние проезжей части, категория улицы, цвет машины и др.) были закодированы с помощью One-Hot Encoding для корректного использования их как в лин. моделях, так и в ML-алгоритмах. Некоторые переменные содержали несколько значений в одной ячейке через разделитель | . Для них применили multi-hot кодирование, создавался отдельный бинарный индикатор для каждой категории, редкие категории объединялись в группу OTHER.

Числовые признаки (возраст автомобиля, количество транспортных средств и др.) приводились к числовому типу, агрегировались до уровня ДТП (если исходно были на уровне участника). Для автомобилей дополнительно рассчитывался возраст ТС и доли старых/новых автомобилей в ДТП.

Из набора признаков были удалены переменные, напрямую связанные с целевой переменной (например, число погибших и число раненых), а также идентификаторы и текстовые описания.

Также было принято решение разбить выборку не рандомно, а по логичным временным промежуткам, чтобы избежать утечки информации

из будущего. Train 01.01.2021-28.02.2025, Validation 01.03.2025 - 31.08.2025 и Test 01.09.2025 - 31.01.2026.

Построение моделей

Логистическая регрессия как базовая модель

В качестве базовой модели в работе используется логистическая регрессия. Целевая переменная принимает значение 1, если в аварии есть хотя бы один погибший. Доля таких случаев в данных составляет около 15%, поэтому задача является несбалансированной.

Рассмотрены две спецификации логистической регрессии: STRICT и EXTENDED. STRICT включает только базовые характеристики ДТП и агрегированные признаки по участникам: тип ДТП, значение дороги, состояние проезжей части, погодные условия, освещение, временные характеристики, признак нахождения вне населённого пункта, возраст автомобилей, а также флаги наличия различных типов транспорта и цветовых групп. EXTENDED использует тот же набор, но дополнительно включает признаки, отражающие масштаб происшествия, такие как общее количество транспортных средств и число участников.

С точки зрения качества STRICT на тестовой выборке показывает ROC-AUC 0.67 и PR-AUC 0.26, при F1 - мере 0.28. Модель обнаруживает 10 из 30 фатальных ДТП ($\text{recall} \approx .33$) и формирует 32 ложноположительных прогноза. EXTENDED демонстрирует более высокие значения ROC-AUC 0.69 и PR-AUC 0.27, а F1 возрастает до 0.35. При этом модель выявляет 24 из 30 фатальных случаев ($\text{recall} \approx 0.80$), но создаёт 82 ложных тревоги. Таким образом, EXTENDED лучше находит опасные аварии, но делает это ценой резкого роста числа ложных срабатываний, тогда как STRICT остаётся более консервативной.




Рисунок 1, 2. Precision–Recall кривые логистической регрессии на тестовой выборке для спецификаций *STRICT* и *EXTENDED*. *EXTENDED* демонстрирует немного более высокую кривую в зоне средних значений recall, что согласуется с более высоким PR-AUC и большей чувствительностью модели.

Интерпретация коэффициентов в обеих спецификациях даёт схожую картину факторов риска. Наиболее сильные эффекты связаны с типом ДТП. Для признака «Наезд на пешехода» средний коэффициент составляет около 0.78, что соответствует увеличению шансов фатального исхода примерно в 2.2 раза. Для «Наезда на велосипедиста» коэффициент около 1.10, то есть шансы возрастают примерно в 3 раза. «Съезд с дороги» имеет коэффициент порядка 0.66, что соответствует росту шансов примерно в 1.9 раза. Эти эффекты устойчивы и сохраняют знак при бутстрэп-оценке.

Состояние проезжей части также оказывает заметное влияние. Для сухого покрытия коэффициент около 0.75, что означает увеличение шансов фатального исхода примерно в 2.1 раза. Дождь и снегопад дают положительные коэффициенты порядка 0.5–0.7, то есть повышают риск примерно на 60–100%. В то же время метель имеет отрицательный коэффициент около –0.68, что соответствует снижению шансов почти в два раза. Такая картина хорошо согласуется с гипотезой о поведенческих

эффектах: в экстремально плохих условиях водители становятся осторожнее, тогда как в «хороших» условиях чаще едут быстрее.

Наличие грузового транспорта является одним из наиболее стабильных числовых факторов. Коэффициент *has truck* составляет около 0.34, что соответствует росту шансов фатального исхода примерно на 40%. Этот эффект сохраняется в обеих спецификациях модели.

Освещение также играет существенную роль. Признак «Светлое время суток» имеет коэффициент около -0.50 , что означает снижение шансов фатального исхода примерно на 40%. Переменная *hour* имеет отрицательный коэффициент около -0.24 , однако этот эффект следует трактовать осторожно, поскольку линейная форма не способна уловить возможную нелинейную зависимость риска от времени суток.

Для оценки устойчивости коэффициентов вместо классических *p-value* использовался бутстрэп (300 переобучений). Признак считался устойчивым, если 95%-доверительный интервал не пересекал ноль. Такой подход выбран из-за шумности данных, большого числа категориальных переменных и использования взвешивания классов. Бутстрэп показал, что эффекты для наезда на пешехода, съезда с дороги, сухого покрытия, светлого времени суток и наличия грузового транспорта являются устойчивыми.

В целом логистическая регрессия выявляет понятную и логически согласованную структуру факторов риска фатальных ДТП. При этом умеренные значения метрик качества подчёркивают сложность задачи и указывают на наличие более сложных, вероятно нелинейных зависимостей, что мотивирует дальнейшее использование более гибких моделей машинного обучения.

L1-LOGIT




Рисунок 3. Precision–Recall кривая L1-регуляризованной логистической регрессии (EXTENDED) на тестовой выборке. Модель демонстрирует высокую полноту при умеренной точности, что соответствует выбранному порогу классификации и ориентации на выявление максимального числа фатальных ДТП.

L1-регуляризованная логистическая регрессия в расширенной спецификации оставляет ненулевыми всего четыре признака, что указывает на очень компактное ядро факторов риска. ДТП на дорогах местного значения связаны с более низкой вероятностью фатального исхода (odds ratio ≈ 0.71), что можно интерпретировать как эффект более низких скоростей и более «городского» режима движения. Сезонность по месяцам имеет положительный эффект (odds ratio ≈ 1.05), что указывает на наличие периодов года с повышенным риском фатальных исходов, вероятно связанных с погодными условиями и освещённостью. Переменная «час» имеет слабый отрицательный эффект (odds ratio ≈ 0.98), что отражает сглаженную линейной модель зависимость риска от времени суток и возможную нелинейность этого эффекта. Средний возраст автомобилей среди участников ДТП оказывает небольшой положительный

эффект (odds ratio ≈ 1.01), что может быть связано с более низким уровнем пассивной безопасности у более старых транспортных средств.

Поиск нелинейных связей с помощью Generalized additive model




Рисунок 4. Generalized additive model. PR curve

GAM-модель демонстрирует ROC-AUC = 0.66 и PR-AUC = 0.24 на тестовой выборке, что существенно превышает случайный уровень ($\approx 7\%$ при доле фатальных ДТП). При выбранном пороге модель достигает Recall ≈ 0.93 , то есть выявляет большинство фатальных случаев, однако характеризуется невысокой точностью (Precision ≈ 0.19), что отражает сложность задачи при выраженном дисбалансе классов и приводит к большому числу ложных срабатываний.




Рисунок 5. Generalized additive model. Partial effects

С точки зрения структуры эффектов, GAM выявил выраженные нелинейные зависимости. Время суток имеет U-образную форму: риск минимален в дневные часы и повышается ночью и поздним вечером. По месяцам наблюдается нелинейный сезонный тренд с ростом риска к осени и началу зимы. Для дня недели фиксируется резкий рост вероятности фатального исхода на одном из краёв распределения (вероятно, выходные дни). Количество уникальных ТС (`n_vehicles`) демонстрирует нелинейную зависимость, тогда как число участников показывает устойчивый положительный тренд: увеличение числа вовлечённых лиц связано с ростом вероятности фатального исхода. Доля старых автомобилей имеет U-образный эффект с повышением риска при высоких значениях. В совокупности результаты подтверждают наличие сложных нелинейных структур, которые не могли бы быть полностью выявлены в линейной логистической модели.

Эти результаты показывают, что линейная логистическая регрессия не способна полностью уловить сложную структуру влияния факторов, тогда как GAM позволяет выявлять более гибкие и экономически интерпретируемые формы зависимости.

CatBoost

CatBoost был использован как более гибкая ML-модель, способная улавливать нелинейности и взаимодействия признаков, которые линейная логистическая регрессия описывает лишь приближённо. Модель обучалась на том же временном разбиении данных, а порог вероятности подбирался на валидационном периоде по максимизации F1. В конфигурации STRICT CatBoost показал на тесте ROC-AUC около 0.68 и PR-AUC около 0.24 при F1 около 0.37, демонстрируя очень высокую полноту: модель находит почти все фатальные ДТП (recall порядка 0.93), но делает это ценой большого числа ложных тревог (precision около 0.23). В расширенной конфигурации EXTENDED качество ранжирования заметно улучшается: ROC-AUC достигает примерно 0.72, а PR-AUC около 0.30, что существенно выше, чем у логистических моделей. При этом характер trade-off остаётся похожим: recall высокий (около 0.87), а precision умеренный (около 0.23), что связано с выбором порога, ориентированного на F1 и максимальное выявление редкого положительного класса.

Анализ важности признаков показывает, что для CatBoost ключевыми оказываются контекст дороги и условия движения: «значение дороги», «освещение», «час суток» и «состояние проезжей части». В EXTENDED-версии дополнительно возрастает роль признаков масштаба происшествия («число участников» и «количество ТС»), а также типа ДТП, что согласуется с ростом PR-AUC и общей способности модели лучше отделять наиболее рискованные случаи.

Интерпретация CatBoost




Рисунок 6. Глобальная важность признаков по SHAP (CatBoost STRICT)

На графике показано среднее абсолютное значение SHAP для каждого признака, отражающее его вклад в предсказания модели в среднем по выборке.

Для более детального анализа структуры выявленных эффектов были использованы SHAP-значения, позволяющие разложить вклад каждого признака в индивидуальные предсказания модели. Глобальный SHAP-график подтверждает, что наибольшее влияние на прогноз фатального исхода оказывают «значение дороги», «освещение», число транспортных средств, час суток и состояние проезжей части. При этом вклад «значения дороги» существенно превышает вклад остальных переменных, что указывает на фундаментальную роль дорожного контекста в формировании риска. В расширенной версии модели усиливается вклад переменных масштаба ДТП и типа происшествия, что согласуется с ростом PR-AUC и общей способностью модели лучше ранжировать наиболее опасные случаи.




Рисунок 7. SHAP beeswarm-график (CatBoost STRICT). Для ряда переменных (час, число ТС, освещение) эффект существенно варьируется между наблюдениями, что указывает на наличие нелинейностей и взаимодействий.

Beeswarm-график позволяет дополнительно проанализировать направление влияния признаков. Для переменной «значение дороги» наблюдается чёткое разделение: отдельные категории систематически смещают предсказания в сторону повышения риска (положительные SHAP-значения), тогда как другие в сторону его снижения. Это означает, что влияние типа дороги не является однородным, а формирует разные режимы риска. Для переменной «освещение» видно, что тёмное время суток чаще связано с положительными SHAP-значениями, тогда как светлое время с отрицательными, что указывает на устойчивый рост вероятности фатального исхода при ухудшении видимости. Вклад числа транспортных средств распределён асимметрично: более высокие значения n vehicles чаще соответствуют положительным SHAP-значениям, что отражает рост риска при увеличении масштаба аварии. При этом

распределение точек демонстрирует неоднородность эффекта, что указывает на наличие взаимодействий с другими признаками.




Рисунок 8. SHAP dependence-график для признака «hour» (час суток)

На SHAP dependence-графике для переменной «час» отчётливо проявляется нелинейная структура, вклад признака меняется по времени суток, причём в ночные и ранние утренние часы SHAP-значения преимущественно положительные, а в дневной период близки к нулю или отрицательны. Логистическая регрессия задаёт для этой переменной один линейный коэффициент и, таким образом, усредняет риск по всему диапазону значений, тогда как CatBoost выявляет смену режимов риска.




Рисунок 9. SHAP dependence-график для признака «n_vehicles» (число транспортных средств)

Аналогично, dependence-график для n vehicles демонстрирует ступенчатый характер влияния, переход от одного к двум участникам и от двух к трём сопровождается различным вкладом в предсказание, причём

эффект дополнительно варьируется в зависимости от типа дороги. Это свидетельствует о наличии взаимодействий, которые не были явно заданы в линейной модели и потому не могли быть ею учтены.




Рисунок 10. SHAP dependence-график для признака «mean_car_age» (средний возраст автомобилей).

Для переменной среднего возраста автомобиля наблюдается слабый, но асимметричный эффект: до определённого уровня вклад близок к нулю, тогда как при более высоких значениях появляются положительные SHAP-значения, что указывает на возможный пороговый характер зависимости. Логистическая регрессия описывает этот признак линейно, тогда как ML-модель допускает существование зон различной чувствительности риска.

Признак	Вклад в риск
Региональная/межмуниципальная дорога	+0.071
Тёмное время суток без освещения	+0.027
Сухое покрытие	+0.008
Час суток	−0.005

Транспортное (количество)	средство	−0.005
------------------------------	----------	--------

Таблица 1. Локальное LIME-объяснение для одного ложноположительного прогноза (CatBoost STRICT)

Таблица иллюстрирует локальное LIME-объяснение для одного ложноположительного прогноза модели CatBoost (STRICT). Видно, что модель повышает вероятность фатального исхода главным образом за счёт дорожного контекста и условий видимости: наибольший положительный вклад вносят признак региональной/межмуниципальной дороги и отсутствие освещения в тёмное время суток. Дополнительный вклад даёт сухое покрытие, тогда как час суток и число транспортных средств в данном случае слегка снижают риск. То есть CatBoost формирует предсказание на основе сочетания нескольких факторов, а не отдельного доминирующего признака. Это подчёркивает способность ML-модели учитывать взаимодействия между условиями движения, которые в линейной логистической регрессии могут быть отражены лишь приближенно.

RandomForest




Рисунок 11, 12. Precision–Recall кривые модели случайного леса на тестовой выборке для спецификаций STRICT и EXTENDED. EXTENDED демонстрирует немного более низкую кривую в зоне малых и больших значений recall, что согласуется с более низким PR-AUC и меньшей чувствительностью модели.

Random Forest показывает устойчивое качество предсказания редкого события в обеих спецификациях. В модели STRICT на тестовой выборке ROC-AUC составляет 0.74, а PR-AUC — 0.30 при базовой доле фатальных исходов около 7%, что означает значительное превышение случайного уровня. При выбранном пороге модель достигает Recall = 0.90, то есть выявляет 90% фатальных ДТП, однако Precision остаётся на уровне 0.24, что отражает большое число ложноположительных прогнозов. EXTENDED-версия демонстрирует несколько более низкие показатели (ROC-AUC = 0.73, PR-AUC = 0.28), при схожем уровне precision и немного меньшем recall. Таким образом, добавление дополнительных признаков не улучшает ранжирующую способность модели, а компактная спецификация STRICT показывает более устойчивый результат.




Рисунок 13. Ранжирование важности признаков на основе перестановок для STRICT конфигурации.

Анализ важности признаков на основе перестановок подтверждает, что ключевыми детерминантами тяжести ДТП являются структурные характеристики происшествия. В обеих моделях наибольший вклад в качество вносят переменные «Вид ДТП» и «Значение дороги», а также день недели (dow). Именно их случайное перемешивание приводит к наибольшему снижению PR-AUC, что указывает на их фундаментальную роль в формировании риска. В STRICT важности выражены более чётко, тогда как в EXTENDED они несколько «размываются», а некоторые дополнительные переменные, такие как «Количество ТС» или month, демонстрируют нулевую или отрицательную importance. Это означает, что расширенный набор признаков не усиливает модель, а частично добавляет шум или избыточную информацию.




Рисунок 14. Ранжирование важности признаков на основе перестановок для EXTENDED конфигурации.

RF STRICT — PDP/ICE (TEST)




Рисунок 15. Графики частичной зависимости STRICT конфигурации для признаков «hours» (время суток), «month» (месяц), «dow» (день недели), «n_vehicles» (число транспортных средств).

Графики частичной зависимости выявляют устойчивые нелинейные эффекты, воспроизводящиеся в обеих спецификациях. Для переменной `hour` наблюдается выраженная временная асимметрия: риск выше в ночные и ранние утренние часы, минимален днём и умеренно возрастает вечером. Переменная `month` демонстрирует сезонность — постепенное увеличение вероятности фатального исхода к осени (9–11 месяцы). День недели также оказывает влияние: риск ниже в середине недели и повышается к её концу. Доля старых автомобилей (`share_old20`) показывает слабый, но положительный эффект. EXTENDED-версия практически не изменяет форму этих зависимостей, что подтверждает устойчивость выявленных закономерностей.




Рисунок 16. Графики частичной зависимости EXTENDED конфигурации для признаков «hours» (время суток), «month» (месяц), «dow» (день недели), «n_vehicles» (число транспортных средств).

В целом результаты свидетельствуют о том, что тяжесть ДТП определяется прежде всего типом происшествия и характеристиками дорожной инфраструктуры, а также временными и календарными факторами. Расширение набора переменных не приводит к улучшению качества и не выявляет новых существенных зависимостей, что делает спецификацию STRICT более предпочтительной с точки зрения устойчивости и интерпретируемости.

Заключение

В рамках работы была проведена комплексная оценка факторов, влияющих на вероятность фатального исхода дорожно-транспортных происшествий в Республике Тыва за период 2021–2026 гг. На основе детализированных карточек ДТП были построены и сопоставлены

линейные эконометрические модели и ансамблевые модели машинного обучения, что позволило не только сравнить их прогностическое качество, но и проанализировать структуру выявленных зависимостей.

Полученные результаты подтверждают, что тяжесть ДТП определяется прежде всего типом происшествия, характеристиками дорожной инфраструктуры и временными факторами. Логистическая регрессия выявляет устойчивые и экономически интерпретируемые эффекты: наезд на пешехода, съезд с дороги, наличие грузового транспорта и отсутствие освещения существенно повышают шансы фатального исхода. При этом качество модели остаётся умеренным (ROC-AUC около 0.67–0.69), что указывает на наличие более сложных, нелинейных зависимостей.

Использование GAM и ансамблевых методов (CatBoost, Random Forest) показало, что риск погибнуть в ДТП имеет выраженную нелинейную структуру. Время суток демонстрирует U-образную зависимость с повышением риска в ночные часы; наблюдается сезонный эффект с ростом вероятности к осени; а также увеличение числа участников ДТП сопровождается нелинейным ростом риска, так как самые опасные виды аварий случаются с двумя ТС. Ансамблевые модели обеспечивают более высокое качество ранжирования (до ROC-AUC $\approx$ 0.74), однако сохраняют проблему большого числа ложноположительных прогнозов, что отражает сложность задачи при выраженном дисбалансе классов.

Сравнение спецификаций STRICT и EXTENDED показывает, что расширение набора переменных не приводит к устойчивому улучшению качества модели и может добавлять избыточную информацию. Наиболее стабильной и интерпретируемой оказывается компактная спецификация

STRICT, в которой ключевыми детерминантами риска выступают тип ДТП, значение дороги, освещённость и временные характеристики.

Таким образом, результаты исследования подтверждают гипотезу о том, что методы машинного обучения позволяют выявлять более сложные и нелинейные зависимости по сравнению с линейными моделями, однако их преимущество проявляется прежде всего в ранжировании риска, а не в резком росте прогностической точности. Практическая значимость работы заключается в возможности использования выявленных факторов для приоритизации инфраструктурных мер (освещение, дорожный контекст), а также для разработки систем раннего предупреждения наиболее опасных сценариев ДТП.



Список научной литературы:

1. Rodionova M., Skhvediani A., Kudryavtseva T. Prediction of Crash Severity as a Way of Road Safety Improvement: The Case of Saint Petersburg, Russia // Sustainability. 2022. Vol. 14. 9840.
2. Becker N., Rust H. W., Ulbrich U. Weather impacts on various types of road crashes: a quantitative analysis using generalized additive models // European Transport Research Review. 2022. Vol. 14. Article 37. DOI: 10.1186/s12544-022-00561-2.